

R

Лекция 6

Advanced dplyr

Задача - на каждой планете из датасета starwars выбрать представителя с наибольшим ростом

top_n

Выбрать из ВСЕЙ таблицы строку с наибольшим height

```
starwars %>% top_n(1, height)
```

```
## # A tibble: 1 x 13
##   name    height   mass hair_color skin_color
##   <chr>    <int>  <dbl> <chr>      <chr>
## 1 Yara~     264     NA  none       white
## # ... with 5 more variables: homeworld <chr>
## #   vehicles <list>, starships <list>
```

top_n

Выбрать из ВСЕЙ таблицы строку с наименьшим height

```
starwars %>% top_n(-1, height)
```

```
## # A tibble: 1 x 13
##   name    height   mass hair_color skin_color ...
##   <chr>    <int>  <dbl> <chr>       <chr>     ...
## 1 Yoda      66     17  white        green     ...
## # ... with 5 more variables: homeworld <chr>,
## #   vehicles <list>, starships <list>
```

group_by(variable)

Разбивает таблицу на подтаблицы по значениям
variable

```
starwars %>% group_by(homeworld)
```

```
## # A tibble: 87 x 13    Специальный объект - tibble
## # Groups:   homeworld [49]
##       name   height   mass hair_color skin_color
##       <chr>   <int>  <dbl> <chr>        <chr>
## 1 Luke~     172     77  blond      fair
## 2 C-3PO     167     75  <NA>       gold
## 3 R2-D2      96     32  <NA>      white, bl~
```

Как выглядит groupby-объект

variable

value1

value2

...

valueN

The diagram illustrates how a single variable, labeled "variable" in bold black text, branches into multiple values: "value1", "value2", "...", and "valueN". Each branch is represented by a thick green arrow pointing to a separate groupby object, which is shown as a table with columns "col1", "col2", "col3", and an ellipsis. The first groupby object has rows with values [1, 3, 3], [5, 5, 7], [1, 0, 9], and an ellipsis. The second groupby object has rows with values [0, 1, 7], [9, -3, 71], [4, 2, 2], and an ellipsis. The third groupby object has rows with values [1, 2, -2], [7, 4, 1], [1, 9, 8], and an ellipsis.

col1	col2	col3	...
1	3	3	
5	5	7	
1	0	9	
...			

col1	col2	col3	...
0	1	7	
9	-3	71	
4	2	2	
...			

col1	col2	col3	...
1	2	-2	
7	4	1	
1	9	8	
...			

Как выглядит groupby-объект

```
starwars %>%
  group_by(homeworld)
```

Tatooine

Naboo

...

Coruscant

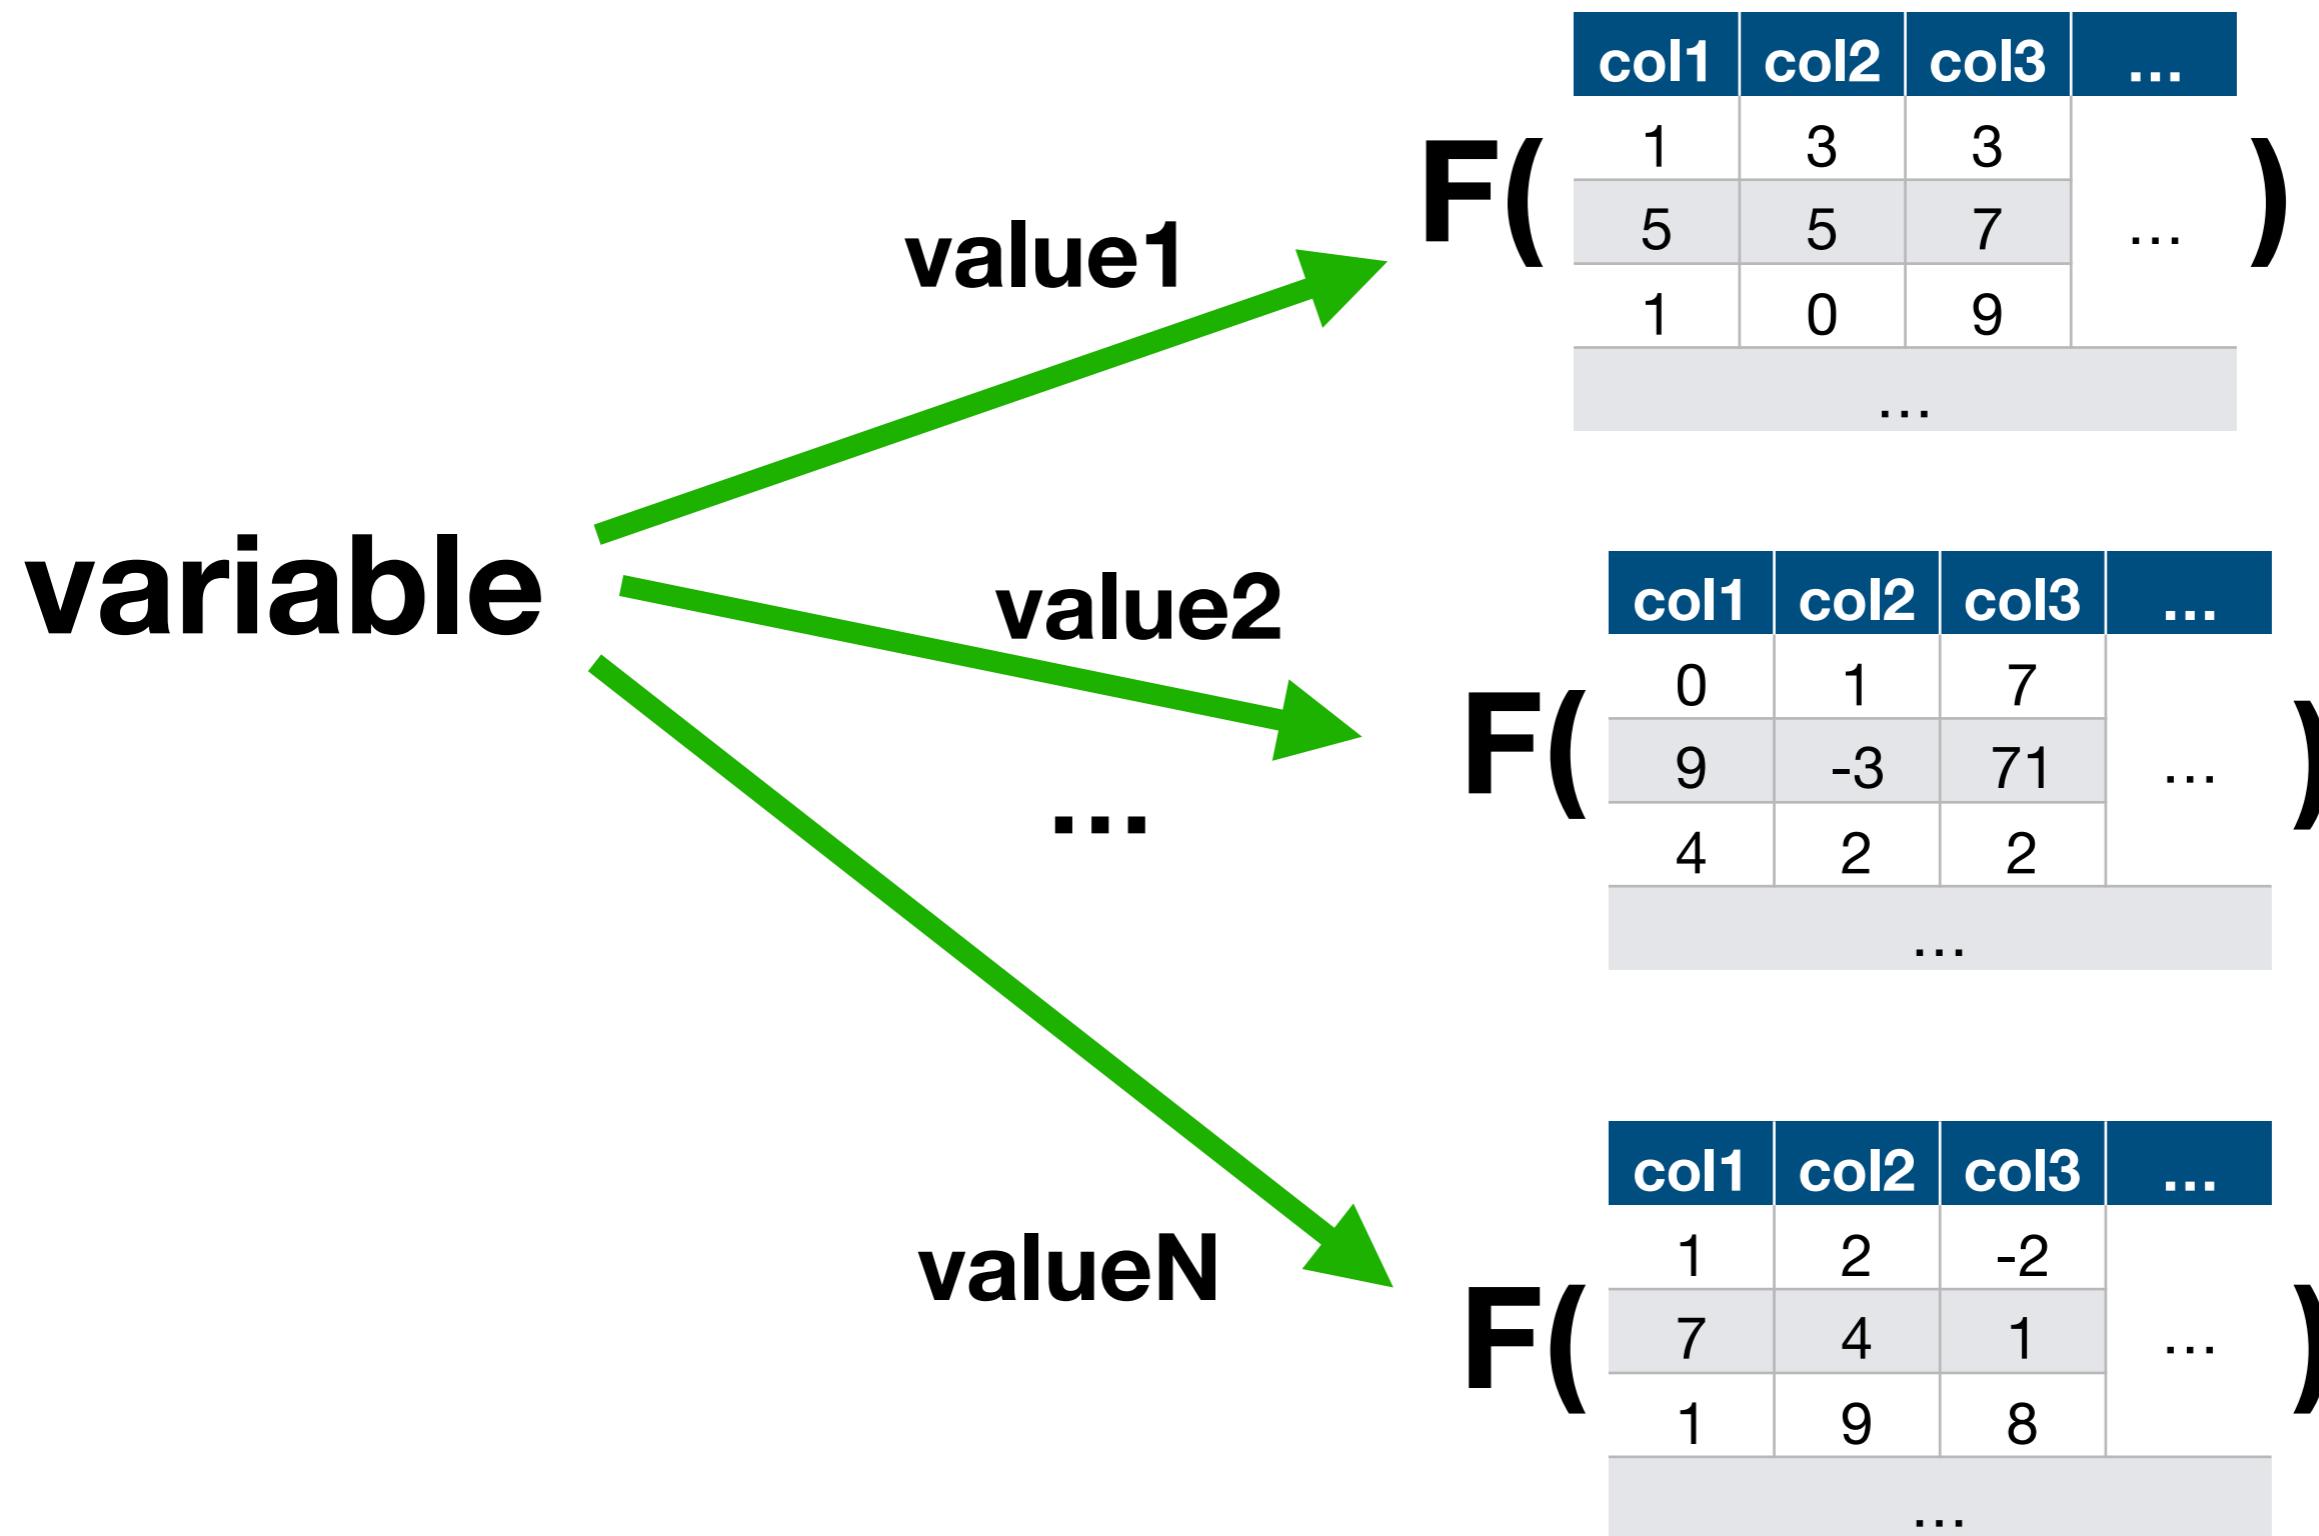
	name	height	mass	...
	<i><chr></i>	<i><int></i>	<i><dbl></i>	
1	Luke Skywalker	172	77	
2	C-3PO	167	75	
3	Darth Vader	202	136	
	
	name	height	mass	...
	<i><chr></i>	<i><int></i>	<i><dbl></i>	
1	R2-D2	96	32	
2	Palpatine	170	75	
3	Jar Jar Binks	196	66	
	
	name	height	mass	...
	<i><chr></i>	<i><int></i>	<i><dbl></i>	
1	Finis Vallo	170	NA	
2	Adi Gallia	184	50	
3	Jocasta	167	NA	
	

Решение нашей задачи?

```
starwars %>%  
  group_by(homeworld) %>%  
  top_n(1, height)
```

```
## # A tibble: 49 x 13  
## # Groups:   homeworld [49]  
##       name    height   mass hair_color skin_color  
##       <chr>    <int>  <dbl> <chr>      <chr>  
## 1 Dart-~     202     136  none       white  
## 2 Obi-~      182      77 auburn, w~ fair  
## 3 Wilh-~     180     NA auburn, g~ fair
```

Как выполняется функция на groupby-объекте



Результат выполнения функции top_n(1) на starwars

```
starwars %>%
  group_by(homeworld) %>%
  top_n(1, height)
```

Tatooine

Naboo

Coruscant

...

	name	height	mass
	<chr>	<int>	<dbl>
1	Darth Vader	202	136
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé Amidala	178	65
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Artoo-Detoo	147	32
.	.	.	.
1	Wedge Antilles	178	75
.	.	.	.
1	Leia Organa Solo	152	50
.	.	.	.
1	Boba Fett	197	90
.	.	.	.
1	Palpatine	196	90
.	.	.	.
1	Leia Organa	152	50
.	.	.	.
1	Obi-Wan Kenobi	182	75
.	.	.	.
1	Qui-Gon Jinn	183	75
.	.	.	.
1	Yoda	169	75
.	.	.	.
1	Padmé		

Решение нашей задачи?

```
starwars %>%  
  group_by(homeworld) %>%  
  top_n(1, height)
```

```
## # A tibble: 49 x 13  
## # Groups:   homeworld [49]  
##       name    height   mass hair_color skin_color  
##       <chr>    <int>  <dbl> <chr>      <chr>  
## 1 Dart-~     202     136  none       white  
## 2 Obi-~      182      77 auburn, w~ fair  
## 3 Wilh-~     180     NA auburn, g~ fair
```

Решение нашей задачи?

```
starwars %>%  
  group_by(homeworld) %>%  
  top_n(1, height)
```

```
## # A tibble: 49 x 13  
## # Groups: homeworld [49]  
##   name    height   mass hair_color skin_color  
##   <chr>    <int> <dbl> <chr>      <chr>  
##   1 Dart-~     202    136 none       white  
##   2 Obi-~      182     77 auburn, w~ fair  
##   3 Wilh-~     180     NA auburn, g~ fair
```

Все еще не избавились от группировки

ungroup()

Снять разбиение на подгруппы

```
starwars %>%  
  group_by(homeworld) %>% ungroup()
```

```
## # A tibble: 87 x 13  
##       name   height   mass hair_color skin_color  
##       <chr>   <int>   <dbl> <chr>      <chr>  
## 1 Luke~     172     77  blond      fair  
## 2 C-3PO     167     75 <NA>       gold  
## 3 R2-D2      96     32 <NA>      white, bl~
```

Решение нашей задачи

```
starwars %>%  
  group_by(homeworld) %>%  
  top_n(1, height) %>%  
  ungroup()
```

```
## # A tibble: 49 x 13  
##   name    height   mass hair_color skin_color  
##   <chr>    <int>  <dbl> <chr>      <chr>  
## 1 Dart-~     202    136 none       white  
## 2 Obi-~      182     77 auburn, w~ fair  
## 3 Wilh-~     180     NA auburn, g~ fair  
## 4 Han ~      180     80 brown      fair  
## 5 Gree~      173     74 <NA>       green
```

Как выполняется ungroup на groupby-объекте

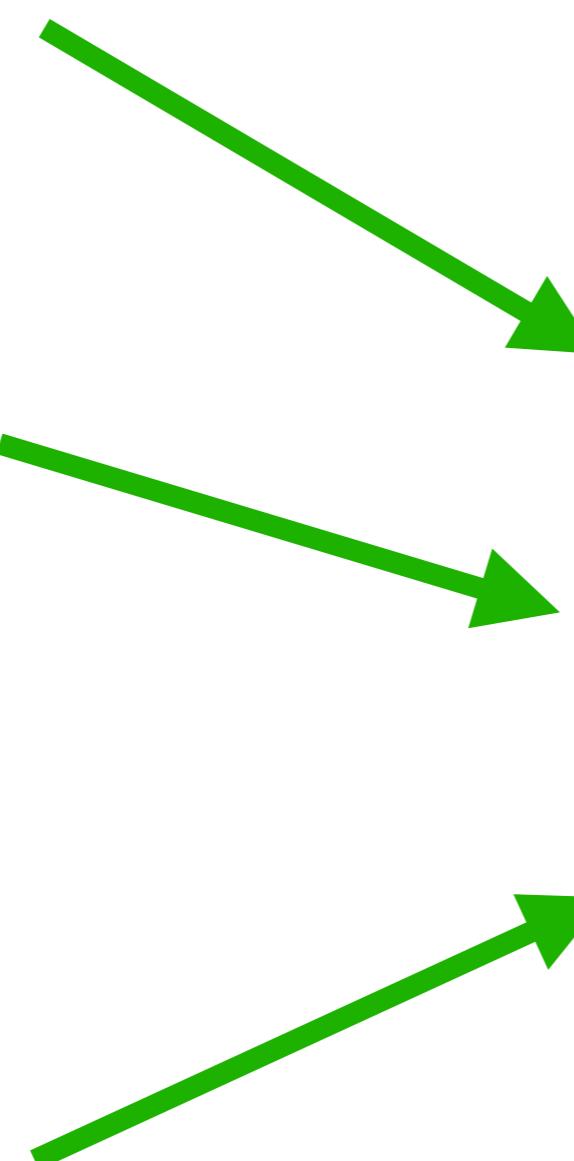
col1	col2	col3	...
1	3	3	
5	5	7	
1	0	9	
...			

...

col1	col2	col3	...
0	1	7	
9	-3	71	
4	2	2	
...			

...

col1	col2	col3	...
1	2	-2	
7	4	1	
1	9	8	
...			



col1	col2	col3	...
1	3	3	
5	5	7	
1	0	9	
2	3	3	
0	1	7	
9	-3	1	
4	2	2	
0	4	3	
1	2	-2	
7	4	1	
1	9	8	
3	5	1	
...			

Результат выполнения функции ungroup

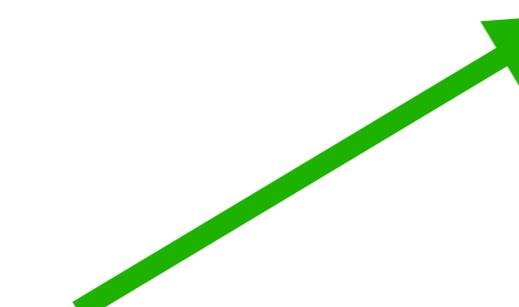
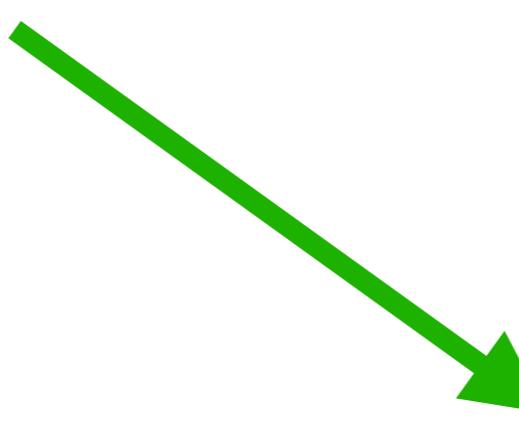
```
name      height  mass  
<chr>    <int> <dbl>  
1 Darth Va~  202   136
```

...

```
name      height  mass  
<chr>    <int> <dbl>  
1 Roos Tarp~ 224   82
```

...

```
name      height  mass  
<chr>    <int> <dbl>  
1 Adi Gal~  184   50
```



```
name      height  mass  
<chr>    <int> <dbl>  
1 Darth V~  202   136  
2 Obi-Wan~  182   77  
3 Wilhuff~  180   NA  
4 Han Solo  180   80
```

...

Задача - на каждой планете из датасета starwars выбрать 2 представителей с наибольшим ростом и посчитать средний для этих двух представителей

```
starwars %>%
  group_by(homeworld) %>%
  top_n(2, height) %>%
  summarise(mean=mean(height))
```

```
## # A tibble: 49 x 2
##   homeworld      mean
##   <chr>        <dbl>
## 1 Alderaan     190.
## 2 Aleen Minor    79
## 3 Bespin       175
## 4 Bestine IV     180
## 5 Cato Neimoidia 191
```

Summarise
снимает одну
группировку с
таблицы

Почему summarise снимает группу

В общем случае у нас нет гарантии, что функция, примененная к подтаблице в группе, независимо от аргументов функции, вернет одну строку

variable

В случае
summarise
такая
гарантия
есть.

value1

value2

...

valueN

F(

col1	col2	col3	...
1	3	3	
5	5	7	
1	0	9	
...			

F(

col1	col2	col3	...
0	1	7	
9	-3	71	
4	2	2	
...			

F(

col1	col2	col3	...
1	2	-2	
7	4	1	
1	9	8	
...			

Почему `summarise` снимает группу

`summarise` от таблицы/подтаблицы обязан возвращать строку.

```
starwars %>%  
  summarise(mean=mean(height, na.rm=T))
```

```
## # A tibble: 1 x 1  
##   mean  
##   <dbl>  
## 1 174.
```

В ней не обязательно один столбец, но это нам и не важно. Важно, что каждой группе соответствует только одна строка, потому группировку можно убрать

```
starwars %>%  
  summarise(mean=mean(height, na.rm=T),  
            sd=sd(height, na.rm=T))
```

```
## # A tibble: 1 x 2  
##   mean     sd  
##   <dbl> <dbl>  
## 1 174.   34.8
```

Что мы не учли в решении задачи?

- А если есть несколько представителей с одинаковым и при этом минимальным ростом?
- А если нет даже 2 представителей данной планеты?

Что мы не учли в решении задачи?

- А если есть несколько представителей с одинаковым и при этом минимальным ростом? (документация top_n говорит, что в этом случае вернуться все такие представители)
- А если нет даже 2 представителей данной планеты? (документация top_n про это ничего не говорит, но можно проверить на игрушечном датасете, что вернется столько, сколько есть представителей вообще)

Важно курить манул



Задача - на каждой планете из датасета starwars найти два наименьших различных значения роста и посчитать средний рост для этих двух представителей

distinct

```
df <- data.frame(x = as.integer(c(10, 4, 1, 1, 1)),  
                  y = as.integer(c(5, 5, 4, 1, 1)))  
print(df)
```

```
##      x y  
## 1 10 5  
## 2  4 5  
## 3  1 4  
## 4  1 1  
## 5  1 1
```

```
df %>% distinct()
```

Убрать повторяющиеся строки

```
##      x y  
## 1 10 5  
## 2  4 5  
## 3  1 4  
## 4  1 1
```

distinct

```
print(df)
```

```
##      x y
## 1 10 5
## 2  4 5
## 3  1 4
## 4  1 1
## 5  1 1
```

```
df %>% distinct(x)
```

**Убрать
повторяющиеся
значения в колонках**

**Как не выбрасывать
другие колонки?**

```
##      x
## 1 10
## 2  4
## 3  1
```

Задача - на каждой планете из датасета starwars найти два наименьших различных значения роста и посчитать среднее этих двух значений

```
starwars %>%  
  group_by(homeworld) %>%  
  distinct(height) %>%  
  top_n(-2, height) %>%  
  summarise(mean=mean(height))
```

```
## # A tibble: 49 x 2  
##       homeworld      mean  
##       <chr>        <dbl>  
## 1 Alderaan     169  
## 2 Aleen Minor    79  
## 3 Bespin       175  
## 4 Bestine IV    180
```

distinct

```
print(df)
```

```
##      x y
## 1 10 5
## 2 4 5
## 3 1 4
## 4 1 1
## 5 1 1
```

```
df %>% distinct(x, .keep_all=T)
```

```
##      x y
## 1 10 5
## 2 4 5
## 3 1 4
```

**Как определяется
то, какую из
повторяющихся
строк оставит?**

distinct

```
print(df)
```

```
##      x y
## 1 10 5
## 2 4 5
## 3 1 4
## 4 1 1
## 5 1 1
```

```
df %>% distinct(x, .keep_all=T)
```

```
##      x y
## 1 10 5
## 2 4 5
## 3 1 4
```

**Как определяется
то, какую из
повторяющихся
строк оставит?**

**Надо посмотреть в
мануал - оставим
первую строку в
таблице**

RTFM



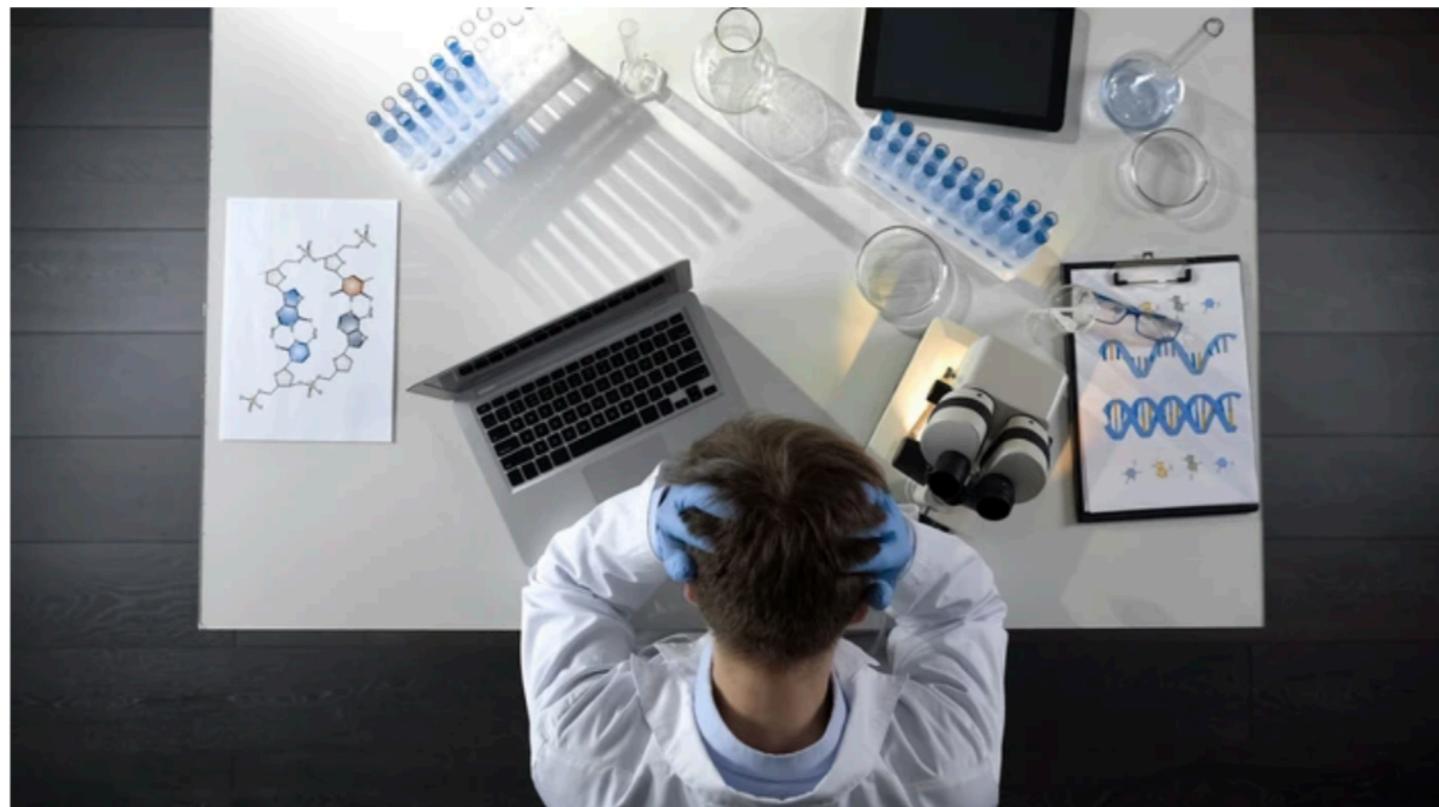
Если не RTFM, то

A Code Glitch May Have Caused Errors In More Than 100 Published Studies

The discovery is a reminder that science is collaborative and ideally self-correcting, but that nothing can be taken for granted.

By [Maddie Bender](#)

Oct 10 2019, 4:00pm [Share](#) [Tweet](#)



Люди “просто” не прочитали документацию питоновской функции `glob.glob` и никак не проверили, что их понимание того, как она работает, совпадает с реальностью

Если не RTFM, да еще и сам М плохо написан

**Misunderstood parameter of NCBI BLAST impacts
the correctness of bioinformatics workflows**

Nidhi Shah, Michael G Nute, Tandy Warnow, Mihai Pop ✉

Bioinformatics, Volume 35, Issue 9, 1 May 2019, Pages 1613–1614,

<https://doi.org/10.1093/bioinformatics/bty833>

Published: 24 September 2018 **Article history ▾**



PDF

Split View

Cite



Permissions



Share ▾

Issue Section: SEQUENCE ANALYSIS

Associate Editor: John Hancock

distinct

```
df %>% distinct(x, y)
```

```
##      x y
## 1 10 5
## 2  4 5
## 3  1 4
## 4  1 1
```

Задача - представители какого цвета глаз оказываются с самым высоким ростом среди всех на планете чаще всего

```
starwars %>%  
  group_by( homeworld) %>%  
  top_n(1, height) %>%  
  count(eye_color) %>%  
  top_n(1, n)
```

Что неверно?

```
## # A tibble: 49 x 3  
## # Groups:   homeworld [49]  
##   homeworld     eye_color     n  
##   <chr>          <chr>      <int>  
## 1 Alderaan       brown        1  
## 2 Aleen Minor    unknown      1  
## 3 Bespin          blue         1  
## 4 Bestine IV      blue         1
```

Задача - представители какого цвета глаз оказываются с самым высоким ростом среди всех на планете чаще всего

```
starwars %>%  
  group_by( homeworld) %>%  
  top_n(1, height) %>%  
  ungroup() %>%  
  count(eye_color) %>%  
  top_n(1, n)
```

```
## # A tibble: 1 x 2  
##   eye_color     n  
##   <chr>       <int>  
## 1 yellow         9
```

Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%  
  select(homeworld, eye_color, height)
```

```
## # A tibble: 87 x 3  
##   homeworld eye_color height  
##   <chr>     <chr>      <int>  
## 1 Tatooine  blue        172  
## 2 Tatooine  yellow      167  
## 3 Naboo     red         96  
## 4 Tatooine  yellow      202  
## 5 Alderaan brown       150
```

**Выбираем
нужные для
решения строки,
далее нужно
сгруппировать
по нескольким
переменным**

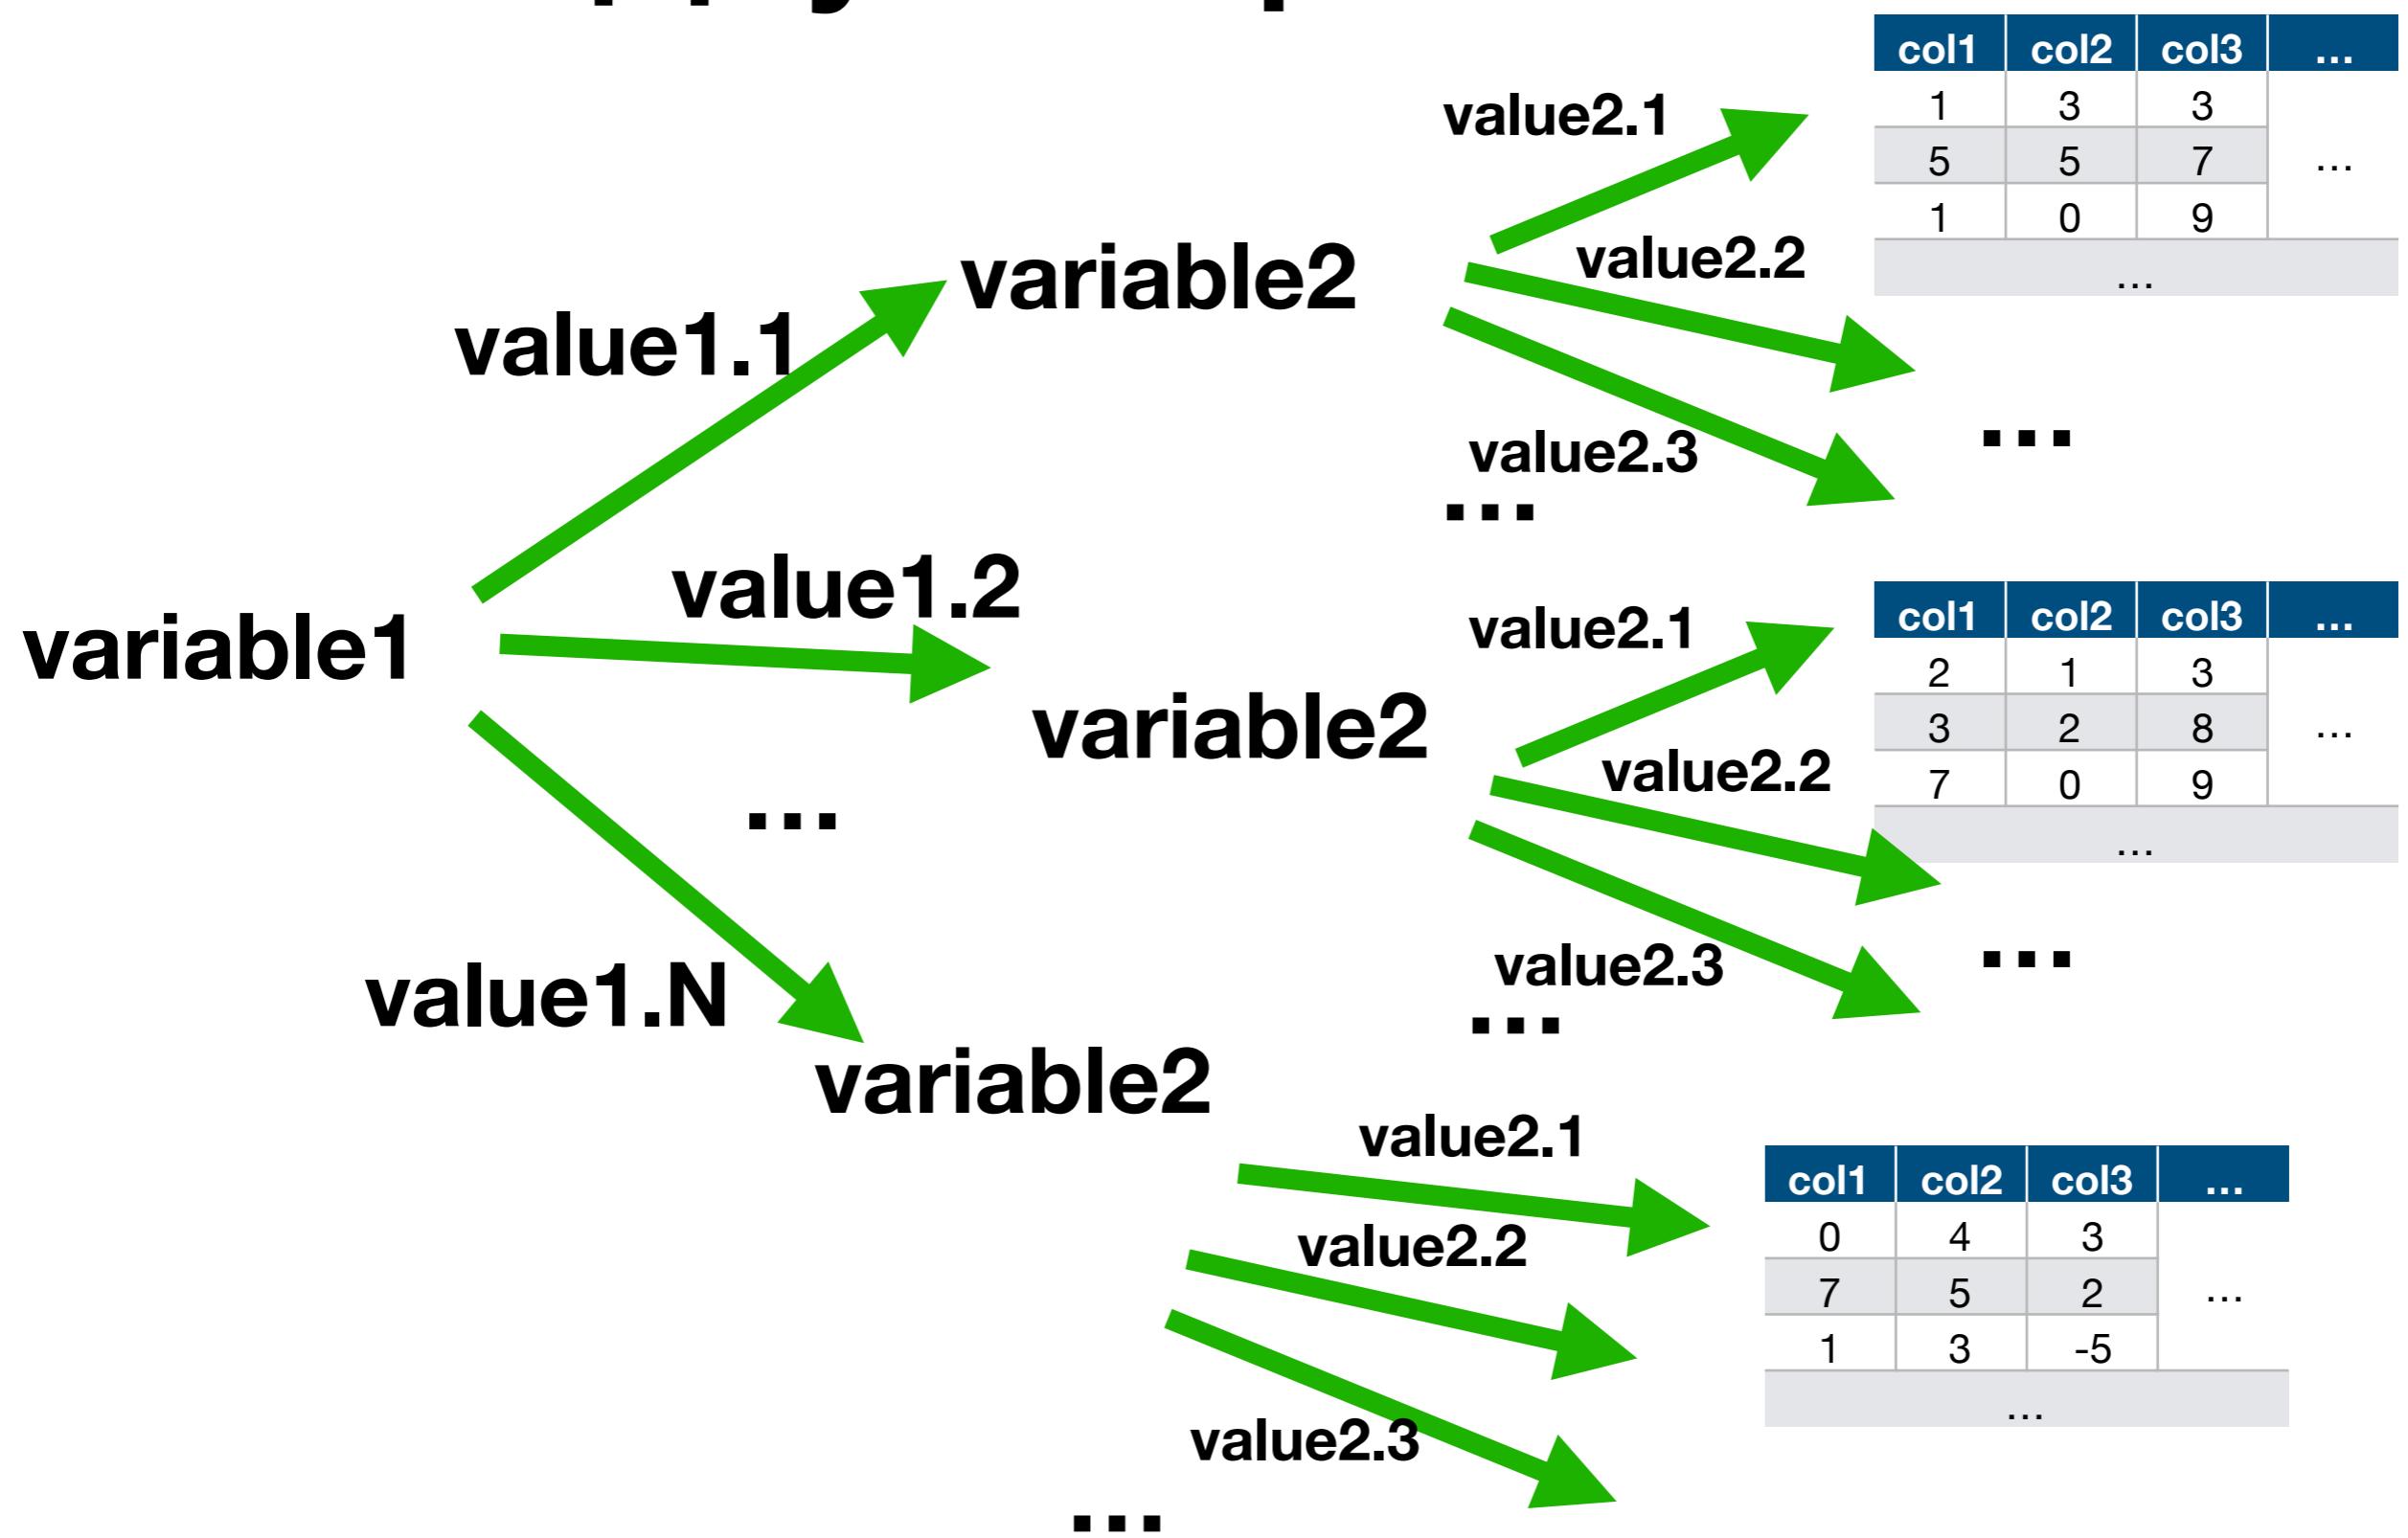
Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%
  select(homeworld, eye_color, height) %>%
  group_by( homeworld, eye_color)
```

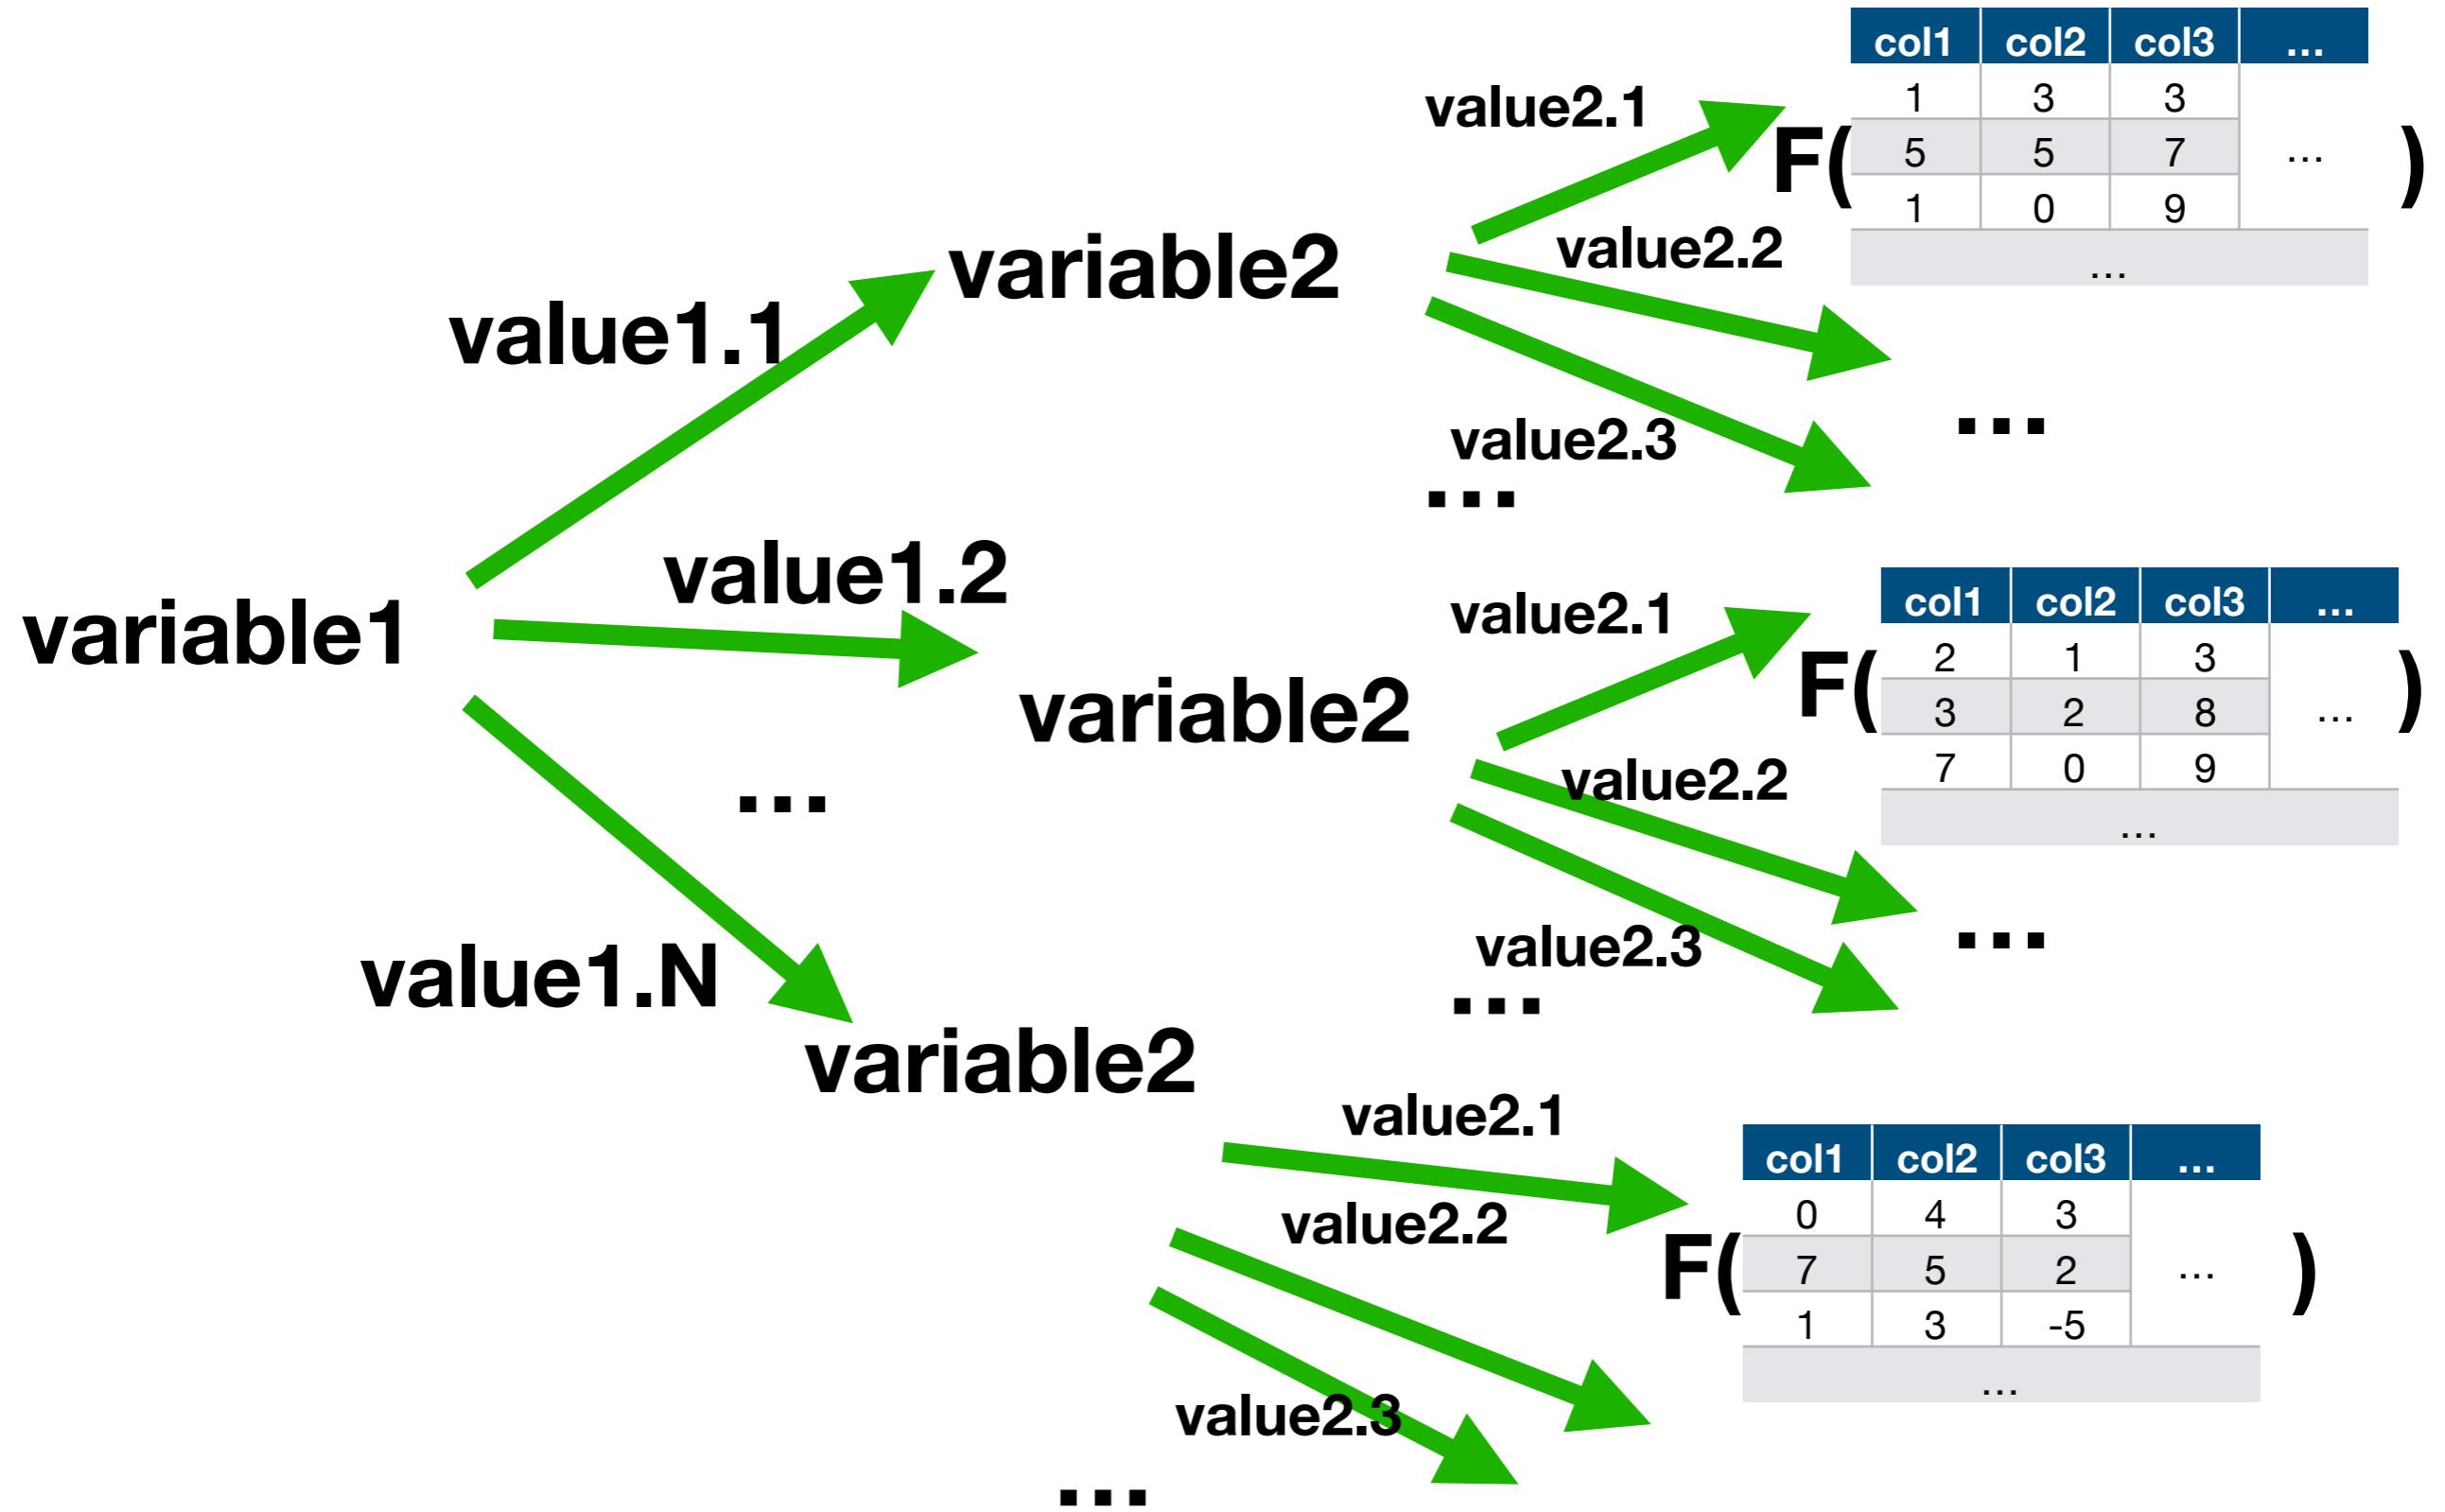
```
## # A tibble: 87 x 3
## # Groups:   homeworld, eye_color [66]
##   homeworld eye_color height
##   <chr>     <chr>    <int>
## 1 Tatooine  blue      172
## 2 Tatooine  yellow    167
## 3 Naboo     red       96
## 4 Tatooine  yellow    202
## 5 Alderaan brown     150
```

Сгруппировали

Как выглядит groupby-объект по двум переменным



Как выполняется функция на groupby-объекте с двумя переменным



Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%  
  select(homeworld, eye_color, height) %>%  
  group_by( homeworld, eye_color) %>%  
  summarise(mean=mean(height))
```

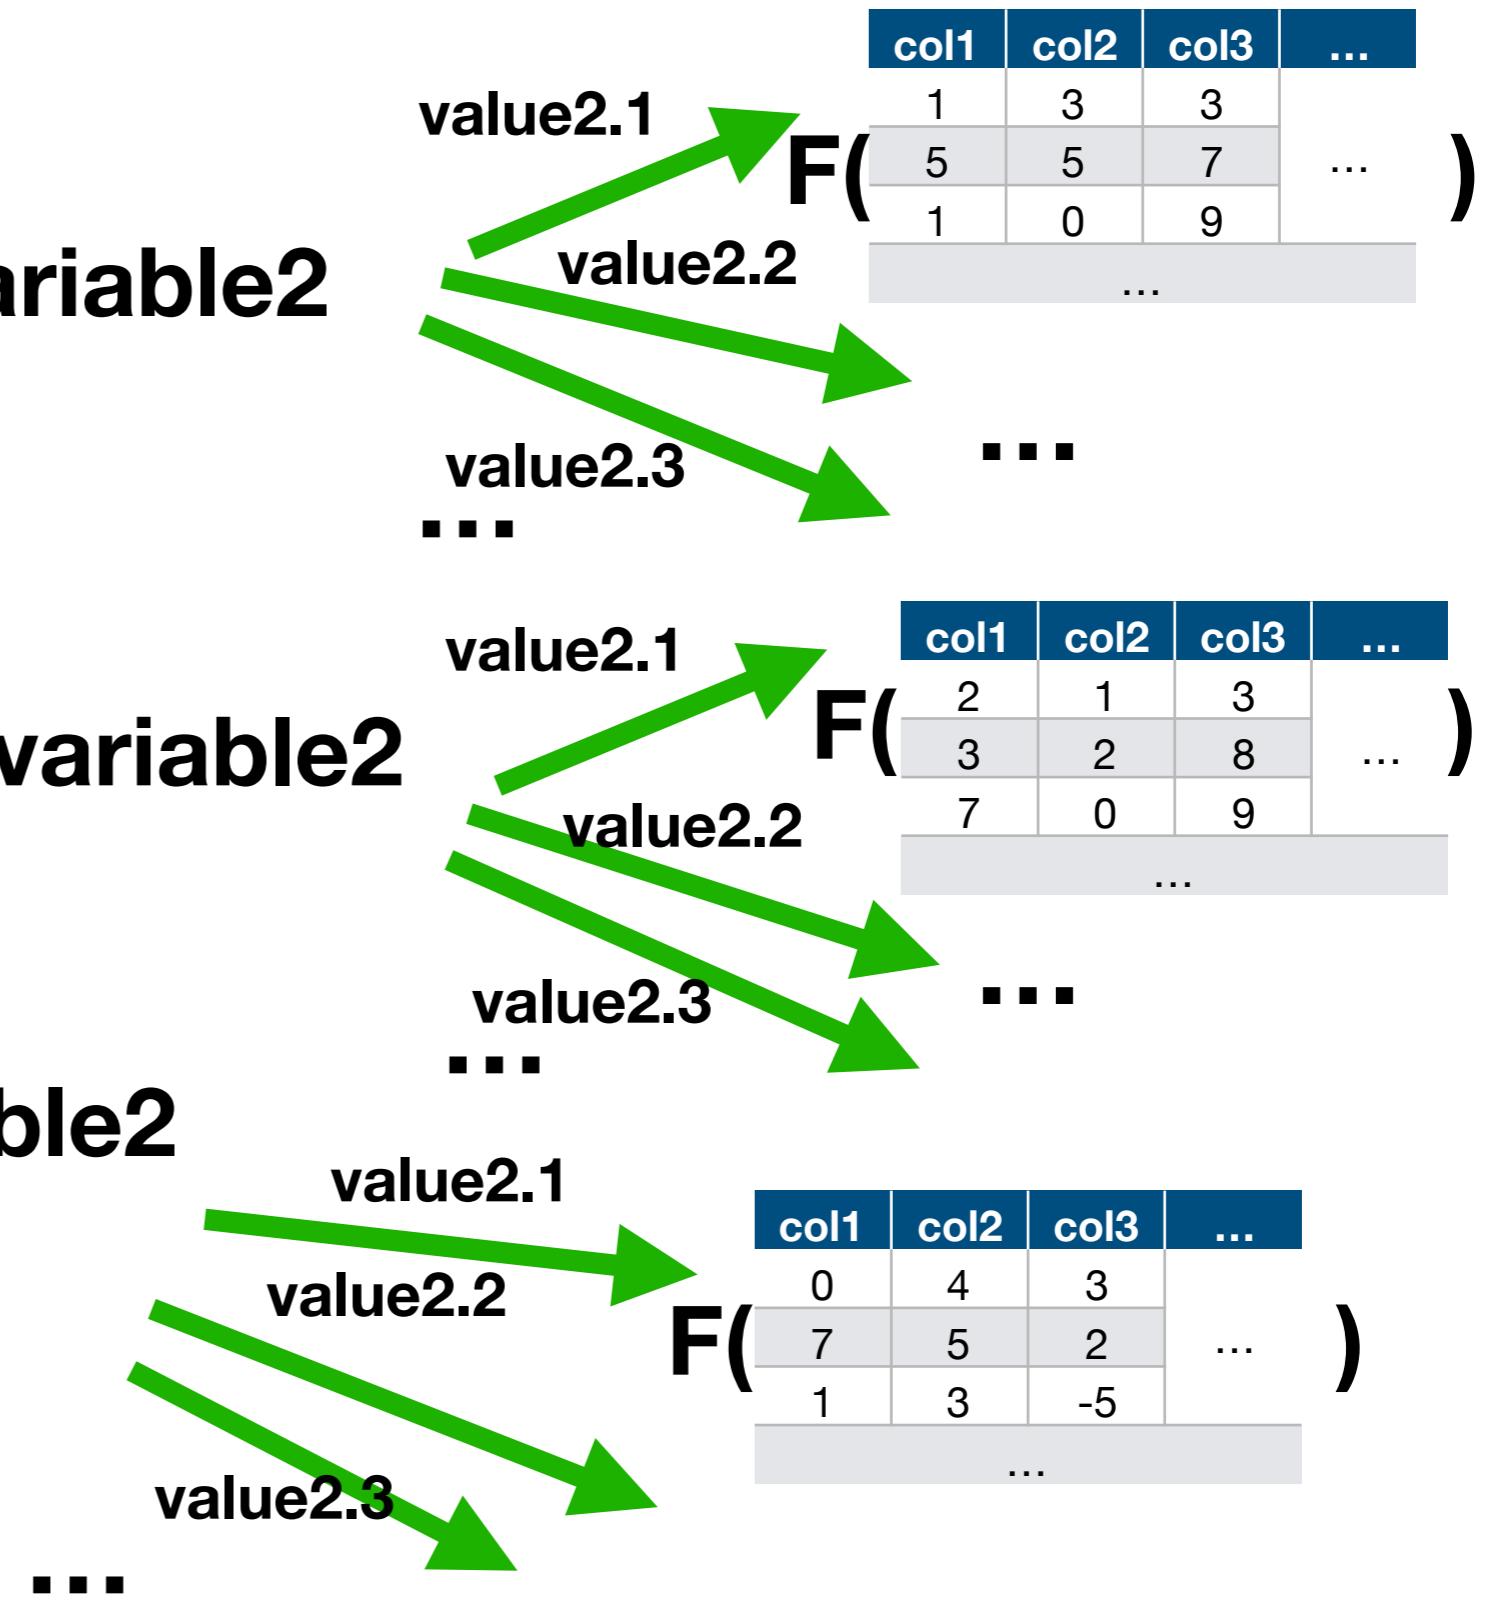
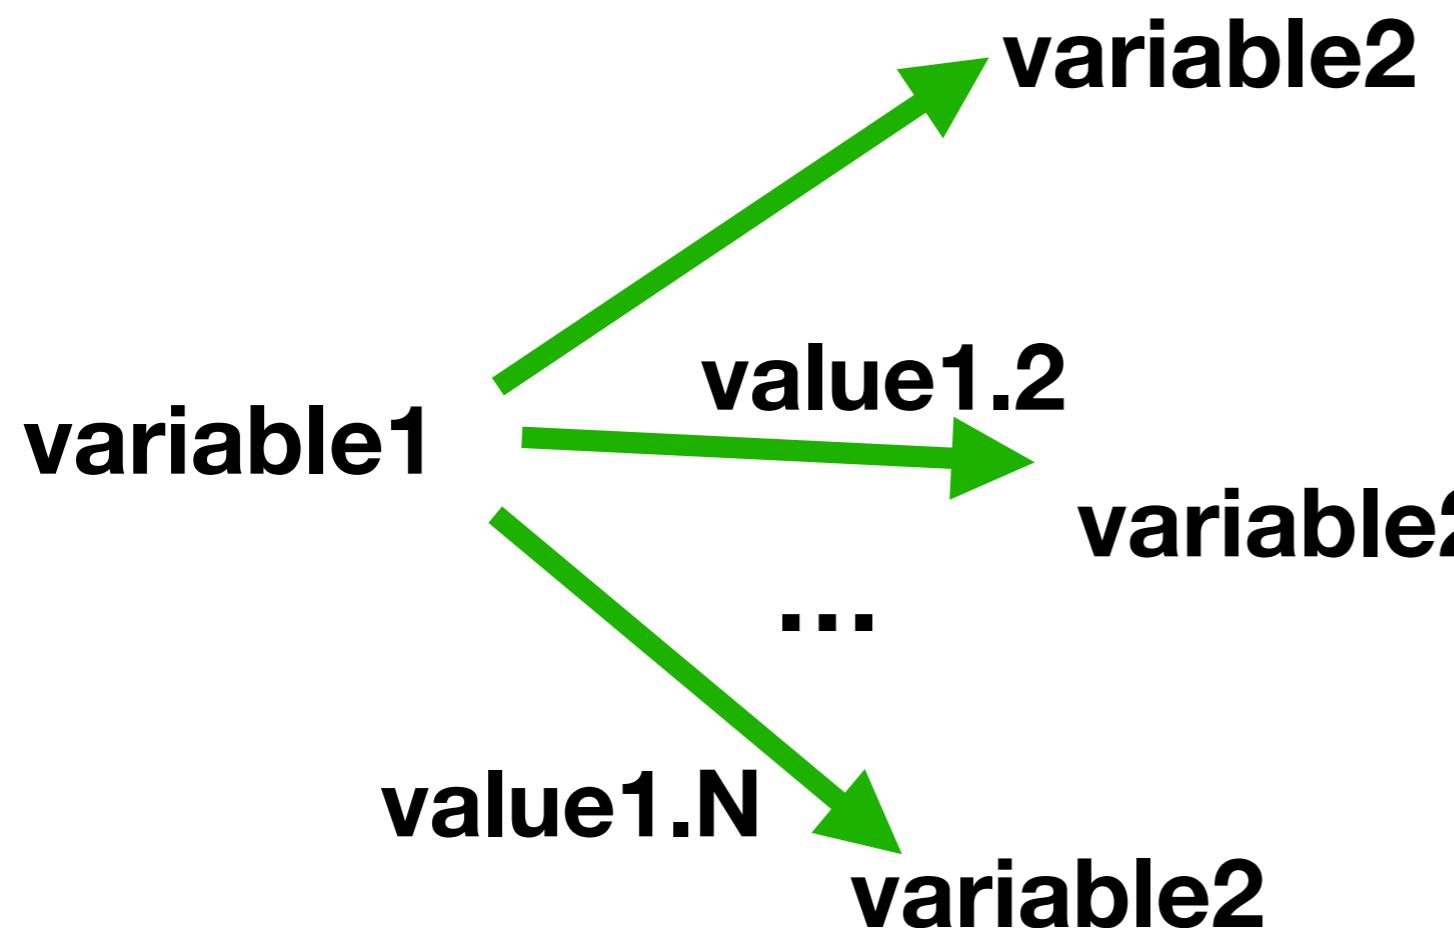
```
## # A tibble: 66 x 3  
## # Groups:   homeworld [49]  
##   homeworld      eye_color    mean  
##   <chr>          <chr>        <dbl>  
##   1 Alderaan     brown       176.  
##   2 Aleen Minor  unknown      79  
##   3 Bespin       blue        175  
##   4 Bestine IV   blue        180
```

**Считаем
среднее в
каждой
подтаблице,
одна строка**

Поведение summarise

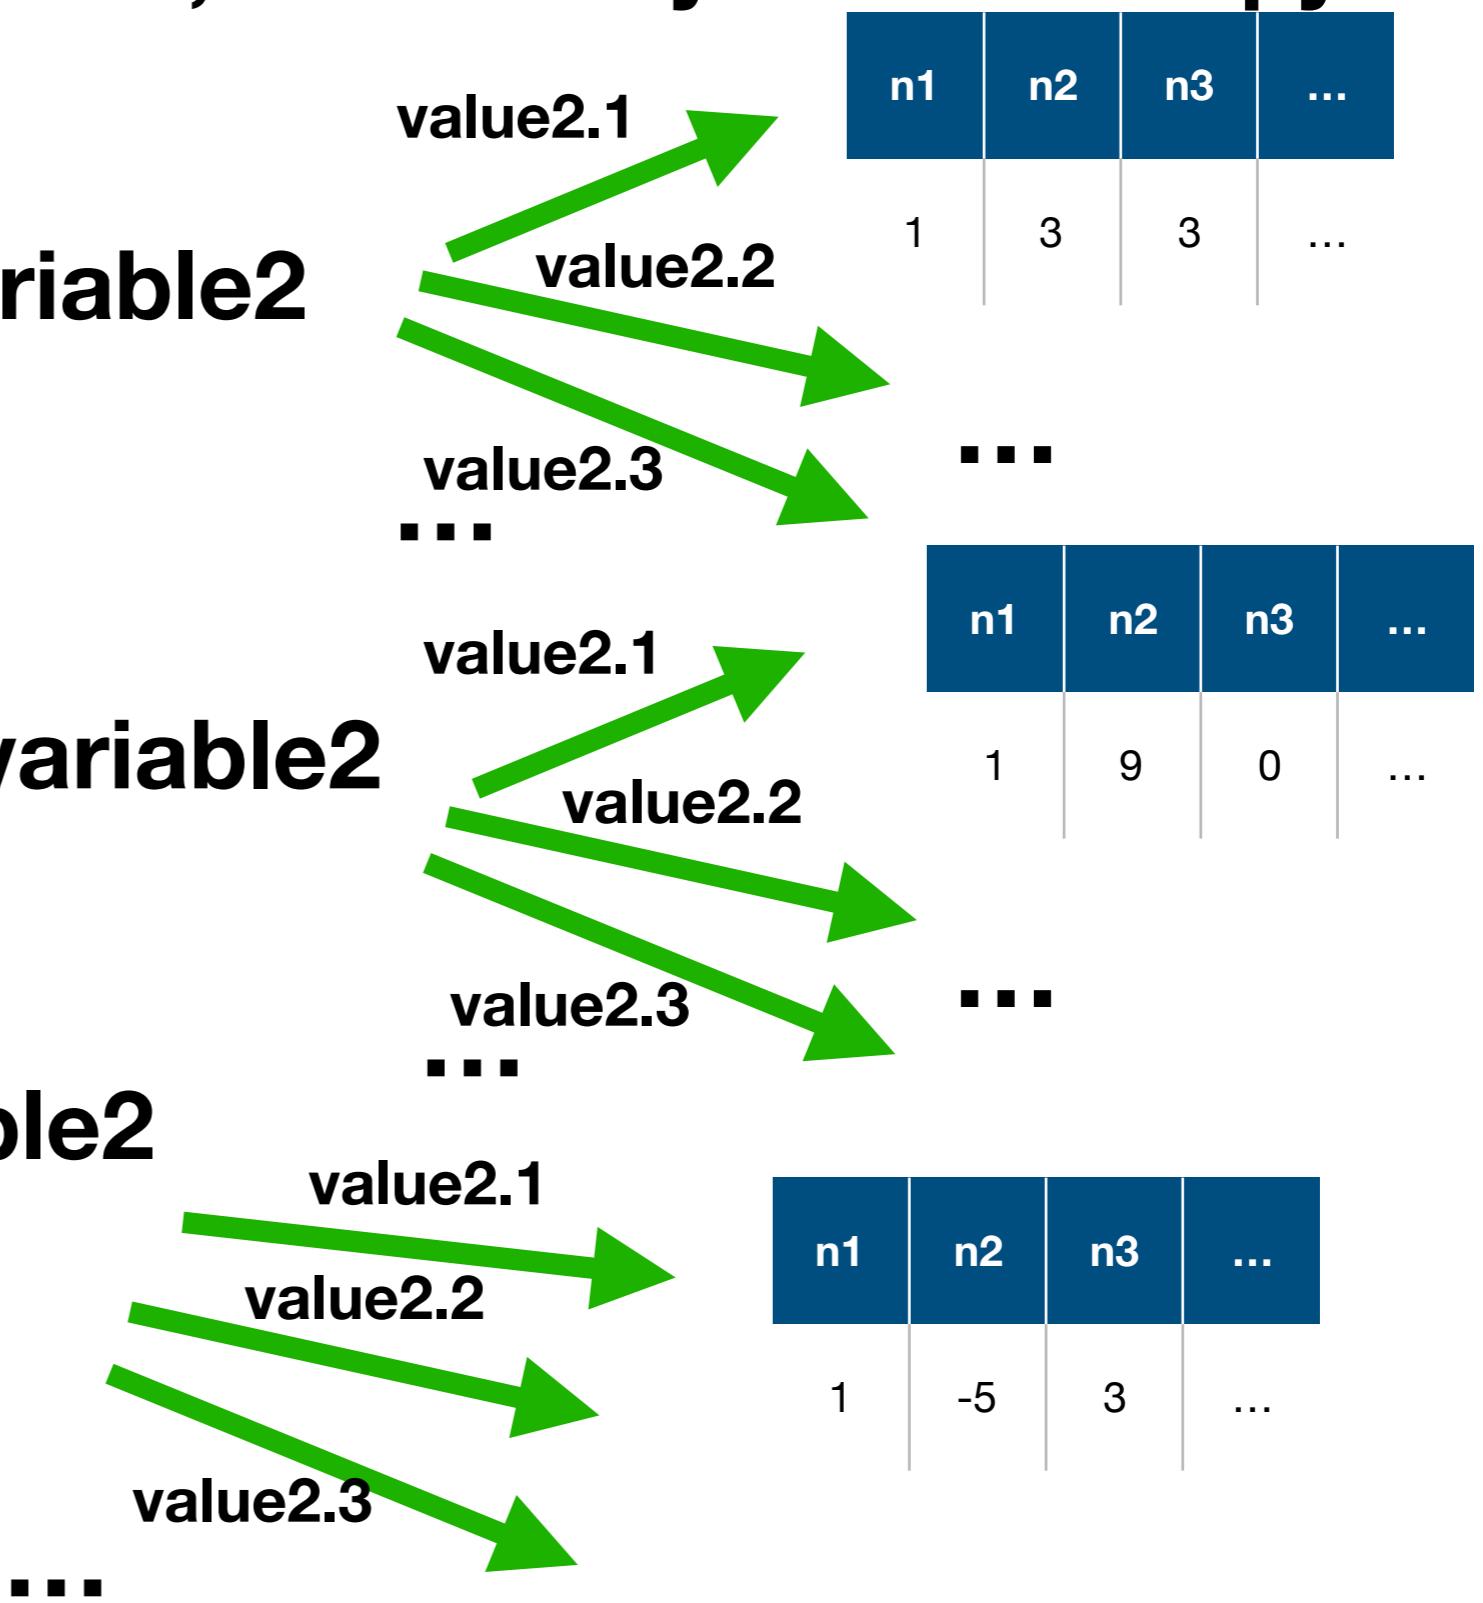
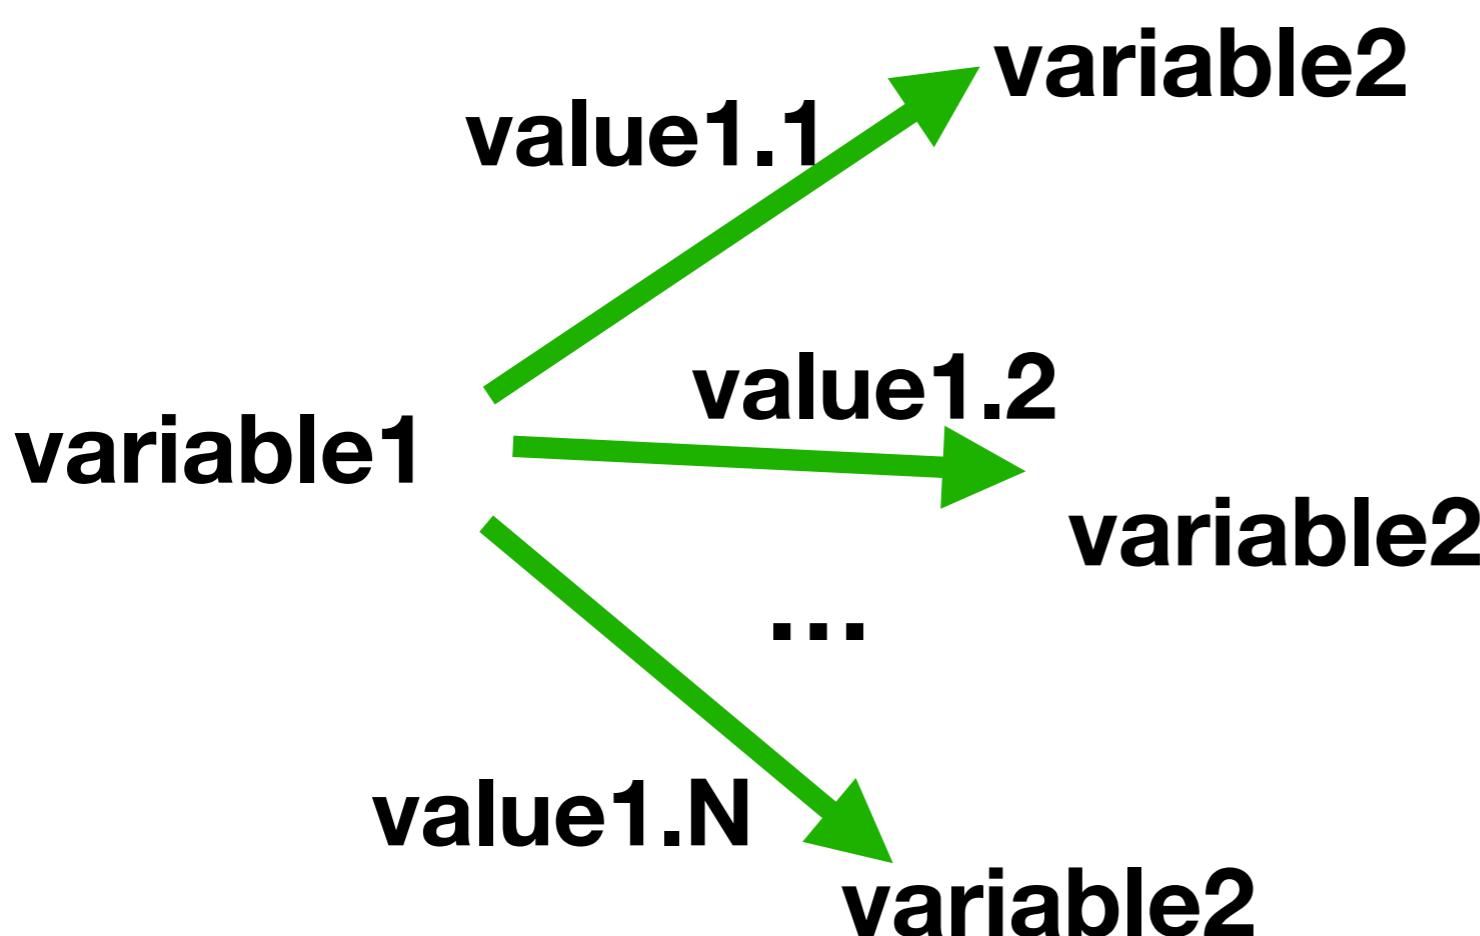
summarise сняло группировку, но только по eye_color, так как далее нет гарантий, что в получившихся группах всего одна строка

F=summarise



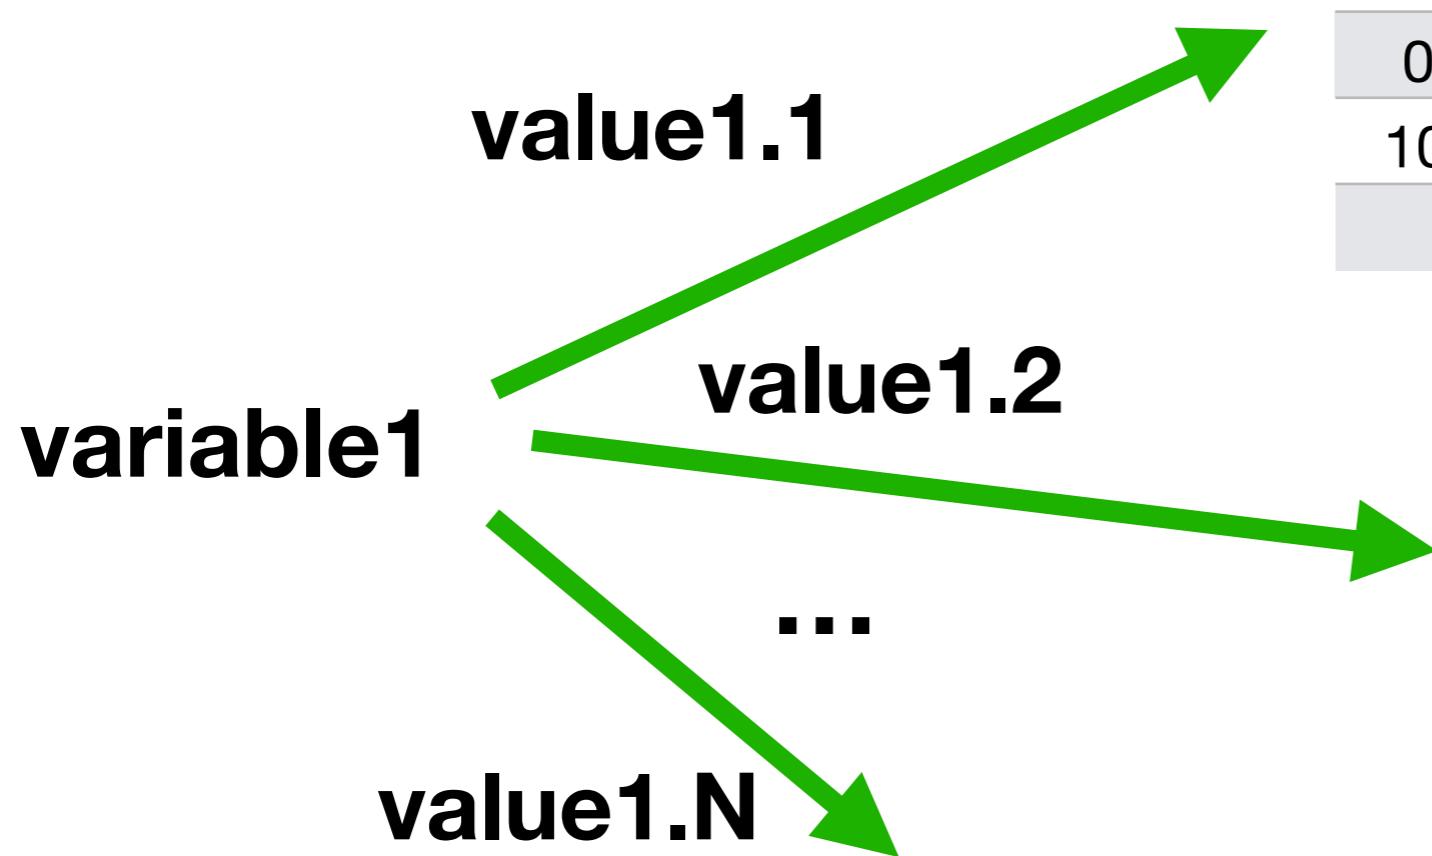
Поведение summarise

summarise сняло группировку, но только по eye_color,
так как далее нет гарантий, что в получившихся группах
всего одна строка



Поведение summarise

summarise сняло группировку, но только по eye_color, так как далее нет гарантий, что в получившихся группах всего одна строка



n1	n2	n3	...
1	3	3	
0	-5	2	
10	12	-2	
...			

n1	n2	n3	...
7	6	0	
3	4	2	
1	7	14	
...			

n1	n2	n3	...
0	-2	-7	
1	2	4	
-9	2	1	
...			

Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%  
  select(homeworld, eye_color, height) %>%  
  group_by( homeworld, eye_color) %>%  
  summarise(mean=mean(height)) %>%  
  ungroup()
```

```
## # A tibble: 66 x 3  
##   homeworld    eye_color     mean  
##   <chr>        <chr>      <dbl>  
## 1 Alderaan    brown      176.  
## 2 Aleen Minor unknown     79  
## 3 Bespin      blue       175  
## 4 Bestine IV  blue       180  
## 5 Cato Neimoidia red      191
```

Убираем группу

Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%  
  select(homeworld, eye_color, height) %>%  
  group_by( homeworld, eye_color) %>%  
  summarise(mean=mean(height)) %>%  
  ungroup() %>%  
  group_by(eye_color) %>%  
  top_n(1, mean)
```

```
## # A tibble: 14 x 3  
## # Groups:   eye_color [14]  
##   homeworld   eye_color      mean  
##   <chr>        <chr>       <dbl>  
## 1 Kalee        green, yellow 216  
## 2 Kamino       black         221  
## 3 Kashyyyk     blue          231  
## 4 Muunilinst   gold          191  
## 5 Naboo        orange        209.
```

**Еще раз
группируем и
выбираем top-1
mean для
каждого цвета
глаз**

Задача - подсчитайте максимальный по всем планетам средний по планете рост для каждого цвета глаз

```
starwars %>%  
  select(homeworld, eye_color, height) %>%  
  group_by( homeworld, eye_color) %>%  
  summarise(mean=mean(height)) %>%  
  ungroup() %>%  
  group_by(eye_color) %>%  
  top_n(1, mean) %>% ungroup()
```

Ответ

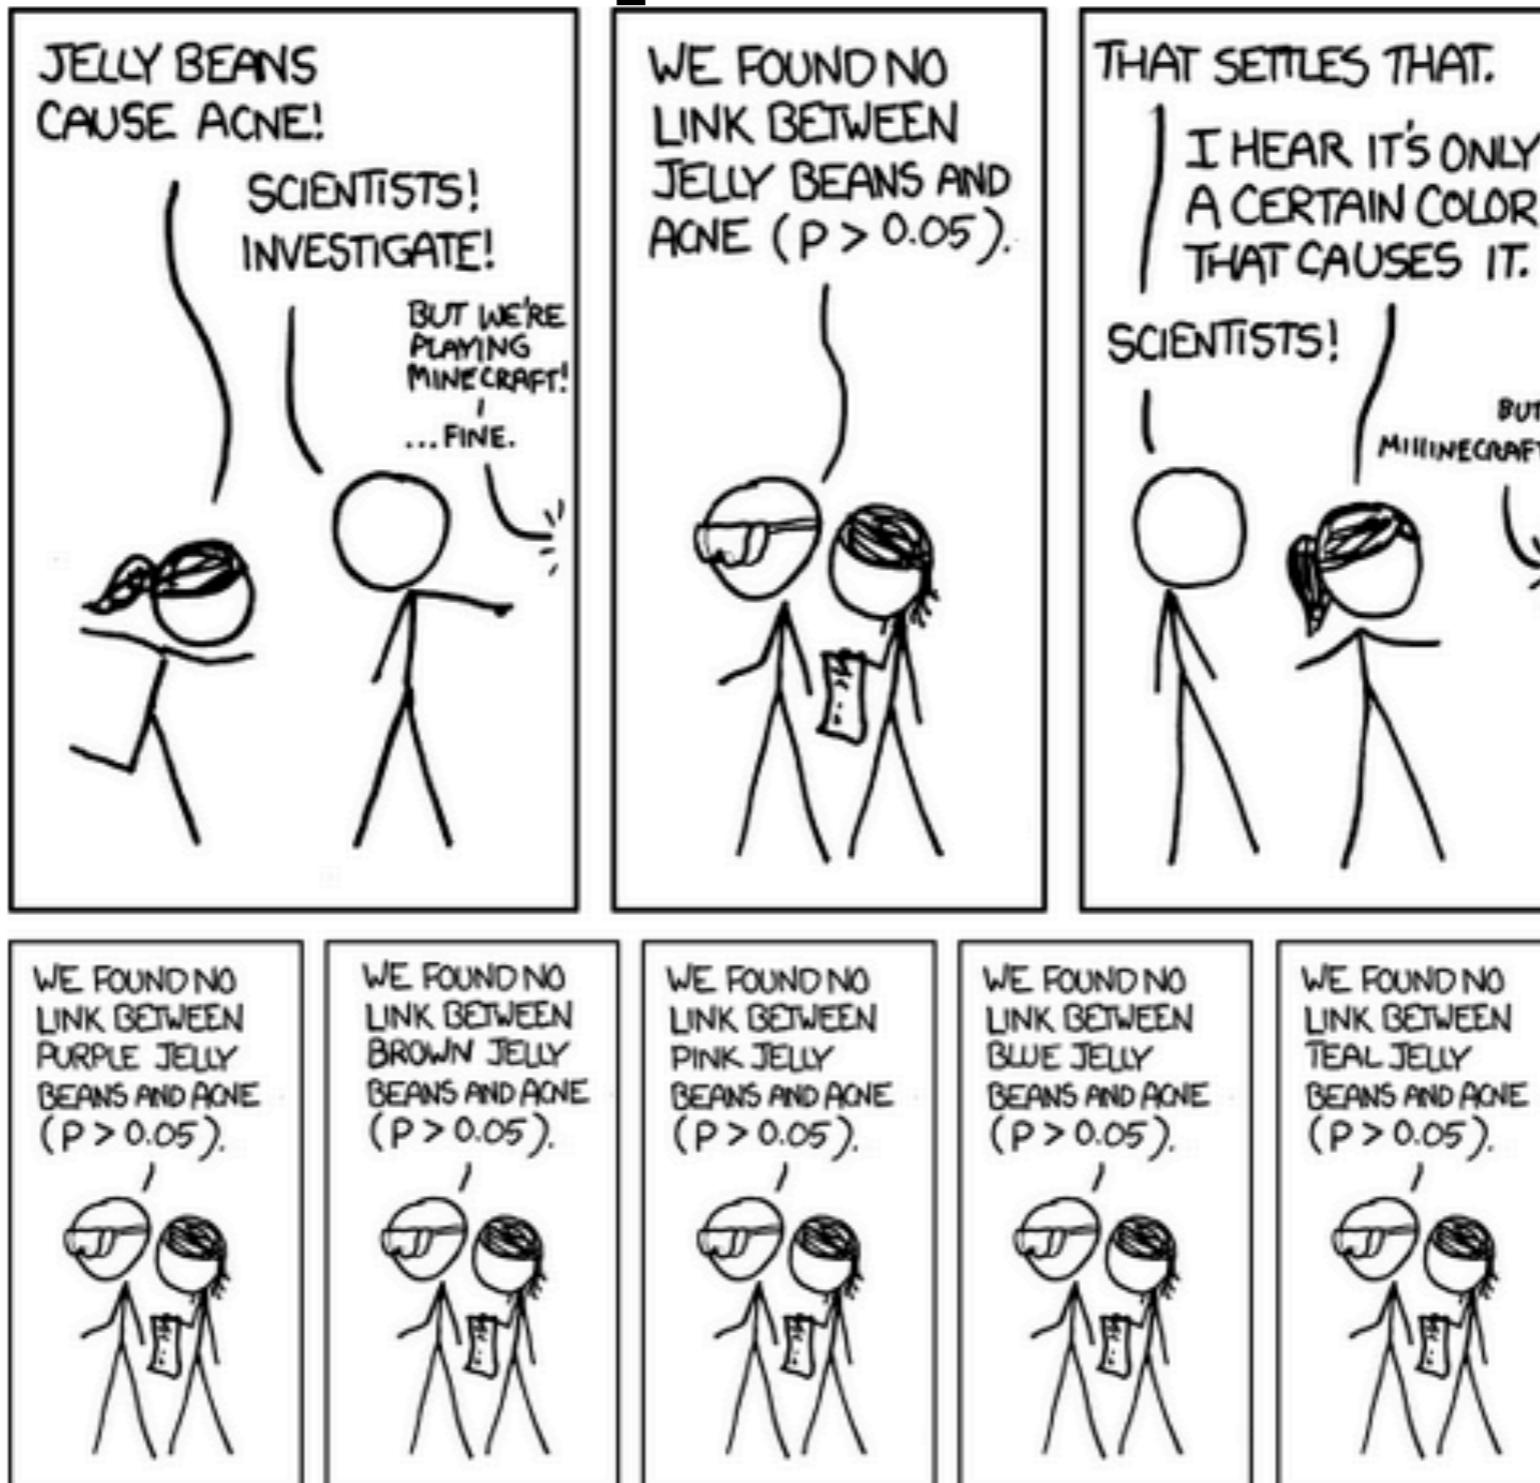
```
## # A tibble: 14 x 3  
##   homeworld eye_color     mean  
##   <chr>      <chr>       <dbl>  
## 1 Kalee      green, yellow 216  
## 2 Kamino     black        221  
## 3 Kashyyyk   blue         231  
## 4 Muunilinst gold        191
```

Множественное тестирование

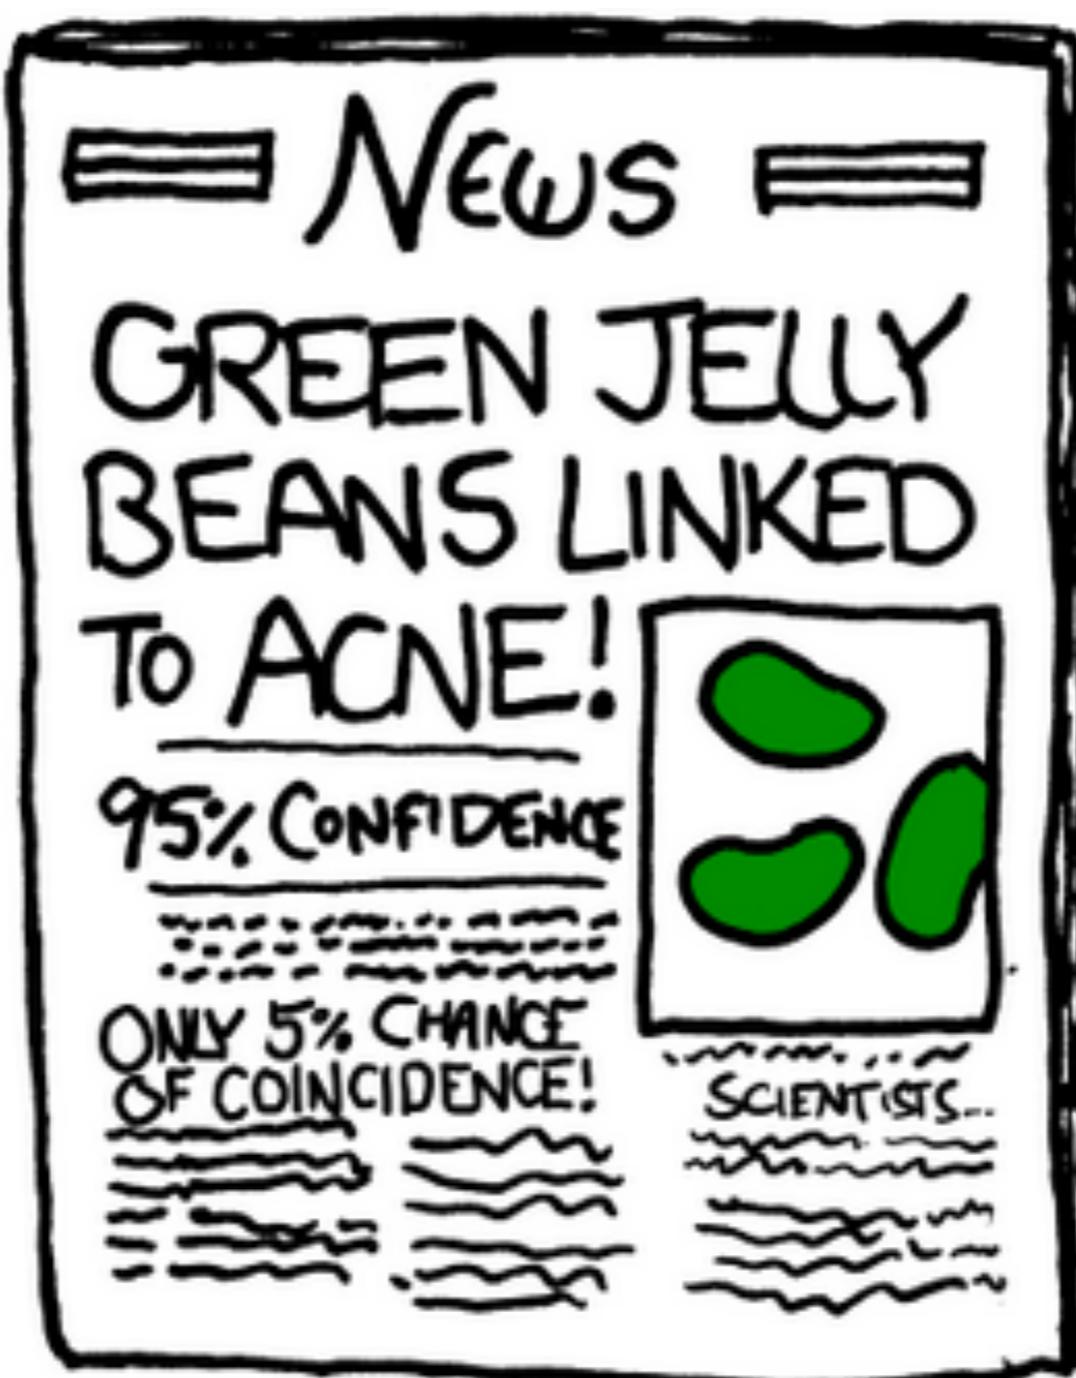
**Не ищите того, чего нет. А то в конечном итоге -
найдете. А это будет ошибка первого рода**

@Игорь

Множественное тестирование



Множественное тестирование



Множественное тестирование

Рассмотрим датасет с 30000 генов, в котором нет ни одного дифференциально экспрессирующегося гена

Проведем t-test для каждого гена. Будем считать ген дифференциально экспрессируемым если $p < 0.05$.

Какова вероятность, что ни один ген не будет помечен как дифференциально экспрессируемый?

Сколько в среднем генов будет помечено как дифференциально экспрессируемые?

Поправки

- FWER (Family-Wise Error Rate) - вероятность, что среди отобранных генов хотя бы один ложно-положительный ген меньше заданного порога (0.05, например)
- FDR (False Discovery Rate) - процент ложно-положительных генов среди отобранных не больше, например, 20%

Смысл alpha разный для двух подходов

FWER

test	p-value
test1	p-value1
test2	p-value2
...	...
testN	p-valueN



test	k	p-value
test1'	1	p-value1'
test2'	2	p-value2'
...
testM'	M	p-valueN'

**Тесты, для которых
мы отвергаем H_0 .**

**Гарантируем, что вероятность того, что
во всей отобранный таблице встретится
хотя бы один тест, для которого мы
ошибочно отвергли H_0 - α**

Наша изначальная таблица

FWER

One-step procedures:

- 1) Sidak correction
- 2) Bonferroni correction

Step-down procedures:

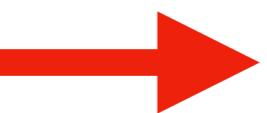
- 1) Holm-Sidak correction
- 2) Holm-Bonferroni correction

Step-up procedures:

Hochberg correction **Не рассматриваем**

FDR

test	p-value
test1	p-value1
test2	p-value2
...	...
testN	p-valueN



test	k	p-value
test1'	1	p-value1'
test2'	2	p-value2'
...
testM'	M	p-valueN'

Наша изначальная таблица

Тесты, для которых
мы отвергаем H_0 .

Гарантируем, что доля генов, для
которых мы ошибочно отвергли H_0 -
 α

```
p.adjust {stats}
```

Adjust P-values for Multiple Comparisons

Description

Given a set of p-values, returns p-values adjusted using one of several methods.

Usage

```
p.adjust(p, method = p.adjust.methods, n = length(p))

p.adjust.methods
# c("holm", "hochberg", "hommel", "bonferroni", "BH", "BY",
#   "fdr", "none")
```

Возвращает скорректированные (adjusted) p-value
Это p-value, при сравнении которых с вашим alpha, меньше
alpha окажутся те p-value, которые были бы отобраны
соответствующим методом

Adjusted p-value

p-value, при сравнении которых с вашим alpha, меньше alpha окажутся те p-value, которые были бы отобраны соответствующим методом

Пример: сколько p-value из списка 0.01, 0.05, 0.04, 0.03, 0.001, 0.015, 0.20 останутся значимыми после поправки Холмса-Бонферонни на уровне значимости alpha=0.05

```
alpha <- 0.05  
pvals <-c(0.01, 0.05, 0.04, 0.03, 0.001, 0.015, 0.20)  
adj_pvals <- p.adjust(pvals, method = 'holm')  
sum(adj_pvals < 0.05)
```

```
## [1] 1
```

Adjusted p-value

One-step procedure

$$p < \frac{\alpha}{N} = \text{thres}$$

На примере Бонферонни, мы можем записать следующее условие иначе

$$\text{adjust_p} = p \cdot N < \alpha$$

Adjusted p-value Step-down procedure

Неверный подход

$$p_k < \frac{\alpha}{N - k + 1} = \text{thres}(k)$$

На примере Холма Бонферонни, мы можем записать следующее условие иначе

$$\text{adjust_}p_k = p_k \cdot (N - k + 1) < \alpha$$

Adjusted p-value

Step-down procedure

Неверный подход

$$p_k < \frac{\alpha}{N - k + 1} = \text{thres}(k)$$

На примере Холма Бонферонни, мы можем записать следующее условие иначе

$$\text{adjust_}p_k = p_k \cdot (N - k + 1) < \alpha$$

Мы должны гарантировать, что все p-value, больше того, которое не прошло порог alpha (включая это p-value), будут больше alpha

Adjusted p-value

Step-down procedure

Верный подход

$$p_k < \frac{\alpha}{N - k + 1} = \text{thres}(k)$$

На примере Холма Бонферонни, мы можем записать следующее условие иначе

$$\text{adjust_}p_1 = p_1 \cdot N < \alpha$$

$$\text{adjust_}p_k = \max(p_k \cdot (N - k + 1), p_{k-1} \cdot (N - k + 2)) < \alpha$$

Adjusted p-value

Step-down procedure.

Пример, Холм-Бонферонни

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	
test6	0.015	3	
test7	0.20	7	

Adjusted p-value

Step-down procedure.

Пример, Холм-Бонферонни

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	$0.001 * 7 = 0.007$
test6	0.015	3	
test7	0.20	7	

Adjusted p-value

Step-down procedure.

Пример, Холм-Бонферонни

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	$\min(0.007, 0.01 * 6) = 0.06$
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	$0.001 * 7 = 0.007$
test6	0.015	3	
test7	0.20	7	

Adjusted p-value

Step-down procedure.

Пример, Холм-Бонферонни

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	0.06
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	0.007
test6	0.015	3	$\min(0.06, 0.015 * 5) = 0.075$
test7	0.20	7	

Adjusted p-value

Step-down procedure.

Пример, Холм-Бонферонни

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	0.06
test2	0.05	6	0.120
test3	0.04	5	0.120
test4	0.03	4	0.120
test5	0.001	1	0.007
test6	0.015	3	0.075
test7	0.20	7	0.200

Adjusted p-value

Step-up procedure

Верный подход

$$p_k < \frac{k}{N} \alpha = \text{thres}(k)$$

На примере поправки Бенджамини-Хохберга, мы можем записать следующее
условие иначе

$$\text{adjust_}p_N = p_N < \alpha$$

$$\text{adjust_}p_k = \min\left(\frac{p_k \cdot N}{k}, \frac{p_{k+1} \cdot N}{k+1}\right) < \alpha$$

Adjusted p-value

Step-up procedure. Пример, Бенджамини-Хохберга

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	
test6	0.015	3	
test7	0.20	7	

Adjusted p-value

Step-up procedure. Пример, Бенджамини-Хохберга

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	
test6	0.015	3	
test7	0.20	7	0.20

Adjusted p-value

Step-up procedure. Пример, Бенджамини-Хохберга

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	$\min(0.05 * 7 / 6, 0.20) = 0.058$
test3	0.04	5	
test4	0.03	4	
test5	0.001	1	
test6	0.015	3	
test7	0.20	7	0.20

Adjusted p-value

Step-up procedure. Пример, Бенджамини-Хохберга

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	
test2	0.05	6	0.058
test3	0.04	5	$\min(0.04 * 7 / 5, 0.058) = 0.056$
test4	0.03	4	
test5	0.001	1	
test6	0.015	3	
test7	0.20	7	0.20

Adjusted p-value

Step-up procedure. Пример, Бенджамини-Хохберга

test	p-value	Порядок в сортировке (k)	adjusted p-value
test1	0.01	2	0.035
test2	0.05	6	0.058
test3	0.04	5	0.056
test4	0.03	4	0.053
test5	0.001	1	0.007
test6	0.015	3	0.035
test7	0.20	7	0.20